

Выборки

Замечание:

Отличие теории вероятности от математической статистики – в статистике неизвестна функция распределения (например, задача оценить вес кильки в балтийском море, пытаемся спрогнозировать вес рыб путём вылавливания).

Пусть X_1, X_2, \dots - независимые одинаково распределённые случайные величины с функцией распределения F . Функция распределения F неизвестная.

Опр.

F – генеральная совокупность (вес всех рыб в Балтийском море, оценки всех студентов БФУ, параметры всех деталей, производимых на каком-то предприятии). Генеральная совокупность считается бесконечной.

Опр.

X_1, \dots, X_n – выборка из генеральной совокупности (например из моря вылавливается 1000 рыб, тогда $n=1000$).

n – размер выборки.

$g(X_1, \dots, X_n)$ – статистика – есть функция выборки (необходима случайная величина).

Примеры статистик:

$M = \max(X_1, \dots, X_n), m = \min(X_1, \dots, X_n);$

$R_n = M - m$ – размах выборки;

$X_1 + \dots + X_n, X_1 + X_3 - X_n.$

Опр.

$X_{(1)} \leq \dots \leq X_{(n)}$ порядковые статистики $X_{1,n} \leq \dots \leq X_{n,n}$ получены из величины X_1, \dots, X_n путем расположения их в порядке возрастания.

(два варианта обозначения, в скобках или через запятую)

Порядковые статистики – зависимые величины и не одинаково распределённые.

$\max(X_1, \dots, X_n) = X_{(n)} = X_{n,n};$

$\min(X_1, \dots, X_n) = X_{(1)} = X_{1,n}.$

Основные задачи статистики:

- По X_1, \dots, X_n найти функцию распределения F .

- Оценка параметров $F(x|a)$ (в статистике функция распределения, как правило, зависит от параметров) (ВАЖНО ДЛЯ СТАТИСТИКИ, при различных параметрах свойства функций отличаются).
- Проверка статистических гипотез ("Проверить, что доля брака в выбранной партии не превосходит 0.5%", так как есть задачи, в которых нужно выбрать четкий, конкретный ответ, к примеру - "Зависимы величины или нет?" "Бракованная партия или нет?").
- Предсказание на основе известных данных новых данных (регрессионный анализ) (зависимость одной переменной от другой - "Как производительность труда влияет на зарплату?").
- Определение атипичных наблюдений (робастный анализ).

Опр.

Эмпирическая (выборочная) функция распределения:

$$F_n^*(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x)$$

$$\text{Где } I(A) = \begin{cases} 1, & A \\ 0, & \bar{A} \end{cases}, i=(1,2,\dots,n)$$

Свойства:

- (1) $F_n^*(-\infty)=0$; $F_n^*(\infty)=1$.
- (2) неубывающая, форма лесенкой.
- (3) $0 \leq F_n^*(x) \leq 1$.

Основное отличие выборочной функции распределения от обычной дискретной – выборочная функция распределения это случайная величина.

Теорема (Гливенко-Картелли):

$$\sup_x |F_n^*(x) - F(x)| \xrightarrow{n \rightarrow \infty} 0$$

Это значит, что при больших n выборочная функция распределения очень точно описывает $F(x)$.

Чем больше n (чем больше наблюдений), тем точнее выборка похожа на генеральную совокупность, однако дольше надо проводить наблюдения.

Замечание:

3-5 наблюдений это не статистика, минимально 20, чем больше тем лучше.

Принципы статистики:

- Выборка должна быть большой – первый принцип статистики

- Презентативная выборка (пример, узнать какие доходы в семье, социологи ездят по особнякам и спрашивают какие доходы, такой подход односторонний, берётся высший класс и спрашиваются доходы, необходимо спрашивать и средний класс и бедный, смотреть пропорции) – второй принцип статистики (разносторонняя статистика).

Опр.

Порядковые статистики: **дискретный случай**, $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$

Располагаем в возрастающем порядке. Некоторые статистики могут совпадать. Пусть n_k – количество совпадений $X_{(k)}$ (так как нет смысла писать одинаковые).

$X_{(1)}$	$X_{(2)}$...	$X_{(k)}$
n_1	n_2	...	n_k

Тогда:

$$n_1 + n_2 + n_3 + \dots + n_k = n$$

n_j – частоты.

$F_n^*(x) = \frac{n_x}{n}$ – число частот меньших или равных x .


$\varpi_i = \frac{n_i}{n}$ – относительные частоты, $\sum_{i=1}^n \varpi_i = n$.

Опр.

Полигоном частот (в дискретном случае) называют ломаную, соединяющую точки $(x_1, n_1), \dots, (x_k, n_k)$.

Полигоном относительных частот называют ломаную, соединяющую точки $(x_1, \varpi_1), \dots, (x_k, \varpi_k)$.

x_i	1	4	5	7
n_i	20	10	14	6




Опр.

В непрерывном случае часто строят гистограмму частот, гистограмму относительных частот. В непрерывном случае n_k – количество наблюдений, попадающих в k -ый интервал.

Высотой сколько людей попало в интервал строим прямоугольник.

Пример:



Замечание:

Пусть $f_n(x)$ – кривая, аппроксимирующая гистограмму.

$f_n(x) \rightarrow f(x)$ – где $f(x)$ – плотность генеральной совокупности (при больших n будет достаточно близка к неизвестной плотности).

Экспоненциальное семейство распределений

Опр.

Пусть:

$f(x|a)$ – плотность, либо функция вероятности.

$f(x) = F'(x)$ – плотность.

$f(x) = P(X=x)$ – функция вероятности (дискретный случай).

Если выполняется $f(x|a) = h(x)c(a)e^{\sum_{i=1}^n w_i(a)t_i(x)}$, где $c, h > 0$, то говорят, что распределение принадлежит экспоненциальному семейству распределений.

Пример:

Нормальное, гамма, бета, биномиальное, Пуассона, отрицательное биномиальное принадлежат экспоненциальному семейству распределений.

(1) Биномиальное:

$$f(x|p) = C_n^x p^x (1-p)^{(n-x)} = C_n^x (1-p)^n e^{x \ln\left(\frac{p}{1-p}\right)}$$

$$h(x) = C_n^x, c(p) = (1-p)^n, w_1 = \ln\left(\frac{p}{1-p}\right), t_1 = x$$

=> биномиальное распределение \in экспоненциальному семейству распределений.

(2) Нормальное:

$$f(x|a, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}}$$

$$c(a, \sigma^2) = e^{-\frac{a^2}{2\sigma^2}}, h=1, w_1 = \frac{-1}{2\sigma^2}, w_2 = \frac{a}{\sigma^2}, t_1 = x^2, t_2 = x$$

=> нормальное распределение \in экспоненциальному семейству распределений.

(3) Распределение Коши – нет. Не разделить x и a :

$$f(x|a, \sigma) = \frac{1}{\left(a \sigma \left(1 + \left(\frac{x-a}{\sigma} \right)^2 \right) \right)}$$

=> распределение Коши не экспоненциальному семейству распределений.

Основная идея экспоненциального семейства распределений:

Всегда есть что-то, что зависит только от x , и оно умножается на что-то, что зависит от только параметра.

Для чего нужны?

Например, для нахождения достаточной статистики, идея нахождения у распределений одного семейства одинаковая. Также сильно облегчает поиск полной статистики.

Выборочное среднее, выборочная дисперсия:

Опр.

Пусть:

$$EX = a, DX = \sigma^2$$

Тогда:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i - \text{выборочное среднее (аналог мат. ожидания).}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \text{ (аналог дисперсии, делится на } n-1 \text{ потому что так надо).}$$

Важное свойство:

$$(n-1)S^2 = \sum_{i=1}^n (X_i^2 - 2\bar{X}X_i + \bar{X}^2) =$$

$$\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 (*)$$

Справедливы и следующие свойства:

$$(1) \quad E \bar{X} = a$$

$$(2) \quad D \bar{X} = D \left(\frac{\sum_{i=1}^n X_i}{n} \right) = \frac{\sigma^2}{n}$$

$$ES^2 = (*) = \frac{1}{(n-1)} \left(E \left(\sum_{i=1}^n X_i^2 \right) - n E \bar{X}^2 \right) =$$

$$(3) \quad \frac{1}{n-1} \left(\left(\sum_{i=1}^n DX_i + (EX_i)^2 \right) - n E \bar{X}^2 \right) =$$
$$\frac{1}{n-1} \left((n\sigma^2 + na^2) - n(D\bar{X} + (E\bar{X})^2) \right) = \sigma^2$$